Algorytmy równoległe 2015 (zad. 2)

Michał Liszcz

2015-11-10

Contents

1	Wst	éb	2
2	Imp	olementacja z wykorzystaniem Apache Spark	2
	2.1	Struktura grafu	2
	2.2	Realizacja algorytmu	2

1 Wstęp

Treść zadania została podana przez prowadzącego:

Zaimplementować algorytm obliczania spójnej składowej (connected components) zgodnie z modelem Pregel [1]. Zasada działania algorytmu:

- 1. Na początku każdy wierzchołek oznaczamy innym znacznikiem (liczbą).
- 2. Każdy wierzchołek wysyła swój znacznik do wszystkich sąsiadów.
- 3. Jeżeli minimum zotrzymanych zniaczników jest mniejsze od własnego, wierzchołek zastępuje swój znacznik przez minimum otrzymanych.
- 4. Powtarzamy krok 2 aż przestaną zachodzić zmiany

2 Implementacja z wykorzystaniem Apache Spark

Implementacja bazuje na strukturze org.apache.spark.rdd.RDD.

2.1 Struktura grafu

Graf zadany jest jako lista **skierowanych** krawędzi, łączących wierzchołki o zadanych indeksach, przykładowo:

```
0 1
0 2
0 3
2 4
5 6
6 7
7 4
8 9
```

TODO: rysunek grafu

Struktura taka ma bezpośrednie przełożenie na RDD:

```
type IntMapRDD = RDD[(Int, Int)]
```

Taki graf można łatwo przekształcić w graf nieskierowany:

```
def makeUndirected(edges: IntMapRDD) = (edges ++ edges.map(_ .swap)).distinct
```

2.2 Realizacja algorytmu

Dążymy do zdefiniowania funkcji transformującej graf w zbiór spójnych składowych:

```
def connectedComponents(graph: IntMapRDD): RDD[Iterable[Int]]
```

Definiujemy połączenia w grafie jako mapę: K -> zbiór wierzchołki wychodzących z K oraz wprowadzamy wagi wierzchołków (każdy wierzchołek zaczyna z waga równą jego indeksowi):

W każdym kroku iteracji zmieniamy wagi: każdy z wierzchołków K otrzymuje wagę będącą minimum z wag jego sąsiadów (i jego samego). Taką operację należy wykonać, unikając zagnieżdżonych operacji na RDD. Można to osiągnąć następująco:

- 1. join (względem klucza) zbiorów connections i weights,
- 2. pobranie wartości (values) powyższego RDD. Otrzymamy pary zawierające wagę wierzchołka K i listę wierzchołków do których ta waga będzie przesłana,
- 3. każdy element z poprzedniego wyniku mapujemy na pary wierzchołek -> nowa waga, wynik wypłaszczamy (flatten)
- 4. poprzedni wynik grupujemy po kluczu, otrzymamy pary wierzchołek -> lista wag które otrzyma od sąsiadów
- 5. mapujemy wartości w poprzednim wyniku, wybierając minimum z zadanej listy

Punkty 4. i 5. można zastąpić jedną operacją: combineByKey(weight => weight, Math.min, Math.min), lub prościej: reduceByKey(Math.min)

Implementacja tych operacji:

```
val newWeights = connections.join(weights).values.flatMap {
   case (indices, weight) => indices map { (_ , weight) }
} reduceByKey(Math.min)
```

Wyliczone nowe wartości wag nie uwzględniają poprzedniej wagi (jeżeli jest najmniejsza, wierzchołek nie powinien zmieniać wagi). Należy złączyć oba zbiory wag, dla każdego wierzchołka wybierając mniejszą wagę:

```
val mergedWeights = weights.join(newWeights)
.mapValues((Math.min _ ).tupled)
```

Powyżej zdefiniowane operacje należy powtarzać, dopóki w wagach zachodzą zmiany. Oczywistym rozwiązaniem wydaje się być rekurencja:

```
@tailrec
def performStep(weights: IntMapRDD): IntMapRDD = {
    val newWeights = connections.join(weights).values.flatMap {
        case (indices, weight) => indices map { (_ , weight) }
    } reduceByKey(Math.min)

val mergedWeights = weights.join(newWeights)
        .mapValues((Math.min _ ).tupled)

if (weights.subtract(mergedWeights).count == 0)
        mergedWeights else performStep(mergedWeights)
}
```

UWAGA: we współczesnych wersjach Apache Spark dostępna jest metoda RDD. is Empty. Można jej użyć zamiast przyrównywania rozmiaru do zera.

Wynik otrzymany z powyższej rekurencji można ostatecznie zamienić na zbiory spójnych składowych transformacja:

```
performStep(initWeights).map(_ .swap).groupByKey.map(_ ._ 2)
```

References

- [1] R. Zadeh, Distributed Algorithms and Optimizations, http://stanford.edu/~rezab/dao/notes/lec8.pdf, 2008.
- [2] Ian Foster, Designing and Building Parallel Programs, www.mcs.anl.gov/~itf/dbpp/.